

심부전증 생존 예측 모델 분석 보고서

본 보고서는 Heart Failure Clinical Records 데이터셋을 활용하여 환자의 생존 여부를 예측하는 머신러닝 모델의 개발 및 분석 결과를 기술합니다.

1. 프로젝트 개요 및 데이터 소개


본 분석의 목적은 환자의 임상 데이터를 기반으로 심부전증 환자의 사망 위험을 조기에 예측하는 것입니다. 분석에는 총 13개의 임상 항목이 포함된 데이터셋이 사용되었습니다.

- 주요 변수: 나이(Age), 빈혈 여부(Anaemia), 고혈압(High Blood Pressure), 당뇨(Diabetes), 혈중 크레아틴(Serum Creatinine), 심장박출률(Ejection Fraction) 등
- 목표 변수: DEATH_EVENT (0: 생존, 1: 사망)

2. 탐색적 데이터 분석 (EDA) 및 인사이트

데이터 시각화를 통해 도출된 주요 인사이트는 다음과 같습니다.


㉠ 변수 간 상관관계 분석



상관관계 히트맵을 통해 변수들 간의 선형적 관계를 파악했습니다. 특정 임상 지표들이 사망 여부와 유의미한 상관관계를 보임을 확인할 수 있습니다.

- 성별과 흡연의 관계: 이 데이터셋에서 남성일수록 흡연을 할 확률이 높다는 점을 보여주고 있습니다. (보통 데이터에서 남성은 1, 여성은 0으로 표시되는데, 남성 그룹에서 흡연자 비율이 더 높기 때문에 0.45라는 양의 상관관계가 나타난 것입니다.)
- 데이터 내 가장 높은 상관관계: 재미있는 점은, '사망여부'를 제외한 일반 변수들끼리의 관계 중에서 이 ****0.45(성별-흡연)****가 가장 높은 수치라는 것입니다.

② 사망 위험 요인 분석



사망 그룹과 생존 그룹의 데이터 분포를 비교 분석한 결과입니다:

- **나이 (Age):** 생존자들은 60세 전후에 많이 분포해 있는 반면, 사망자들은 70~80대 이상의 고령층에서 상대적으로 높은 비율을 보입니다. 나이가 많을수록 심부전 예후가 좋지 않을 가능성이 큼을 시사합니다.
- **심장박출률 (Ejection Fraction):** 생존자들은 대체로 35~45% 사이에 집중되어 있으나, 사망자들은 30% 이하의 낮은 수치에서 빈도가 급격히 높아집니다. 심장의 펌프 능력이 떨어질수록 생존 위험도가 직결됨을 보여줍니다.
- **혈중 크레아틴 (Serum Creatinine):** 생존자들은 정상범위인 1.0 근처에 밀집되어 있는 반면, 사망자 분포는 2.0 이상의 높은 수치까지 넓게 퍼져 있습니다. 이는 신장 기능 저하가 심부전 환자의 사망 위험을 높이는 강력한 요인임을 나타냅니다.
- **관찰 기간 (Time):** 가장 뚜렷한 차이를 보이는 변수입니다. 사망자들은 대부분 관찰 초기(약 100일 이내)에 집중되어 있습니다. 즉, 위험 고비를 넘기고 일정 기간 이상 생존한 환자들은 이후 장기 생존 가능성이 비약적으로 높아짐을 의미합니다.

3. 분석 방법론 (Methodology)

- **데이터 전처리:** 변수 간 스케일 차이를 보정하기 위해 `StandardScaler`를 적용하여 정규화를 수행했습니다.


- **모델링:** 이진 분류 문제에 적합한 로지스틱 회귀(Logistic Regression) 알고리즘을 사용했습니다.
- **평가 지표:** 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1 Score, 그리고 ROC-AUC 점수를 활용하여 모델 성능을 다각도로 검증했습니다.

4. 모델 성능 평가 (Model Performance)


개발된 모델은 테스트 데이터셋에 대해 다음과 같은 우수한 성능을 보였습니다.

ROC 곡선 (Receiver Operating Characteristic Curve)

- **정확도 (Accuracy): 88.33%** - 전체 케이스 중 약 88%를 정확하게 예측했습니다.
- **AUC Score: 0.9409** - ROC 곡선 아래 면적이 0.94로, 모델의 변별력이 매우 뛰어남을 의미합니다(1에 가까울수록 우수).



정밀도-재현율 곡선 (Precision-Recall Curve)



클래스 불균형이 있을 때 유용한 지표인 정밀도(Precision)와 재현율(Recall)의 변화를 임계값(Threshold)에 따라 시각화했습니다. 이를 통해 모델의 임계값을 조절하여 정밀도와 재현율 간의 최적의 균형점을 찾을 수 있습니다.

임계값(Threshold) 변화에 따른 성능 비교

`Binarizer` 를 사용하여 임계값을 조절하며 성능 변화를 관찰했습니다.

임계값 (Threshold)	정확도 (Accuracy)	정밀도 (Precision)	재현율 (Recall)	F1 Score	비고
0.40	0.8667	0.7391	0.8947	0.8095	재현율 최우선 (놓치는 환자 최소화)
0.45	0.8667	0.7895	0.7895	0.7895	균형점 1
0.50	0.8833	0.8750	0.7368	0.8000	기본값 (정밀도 준수)
0.55	0.8667	0.8667	0.6842	0.7647	
0.60	0.9000	1.0000	0.6842	0.8125	정밀도 최우선 (확실한 환자만 예측)

- **재현율 중시:** 실제 사망 환자를 놓치지 않는 것이 중요하다면 임계값을 **0.4**로 낮추어 재현율을 0.89까지 높일 수 있습니다.
- **정밀도 중시:** 오진을 줄이는 것이 중요하다면 임계값을 **0.6**으로 높여 정밀도를 1.0(100%)까지 확보할 수 있습니다.

5. 결론 및 제언

본 분석을 통해 임상 데이터만으로도 심부전증 환자의 사망 위험을 높은 정확도로 예측할 수 있음을 확인했습니다. 특히 나이, 혈중 크레아틴 농도, 박출계수 등의 지표가 중요한 예측 인자로 작용함을 알 수 있습니다. 이러한 모델은 의료 현장에서 고위험군 환자를 조기에 선별하고 적절한 치료 계획을 수립하는 데 보조적인 도구로 활용될 수 있습니다.