

학생 성적 예측 분석 보고서

1. 프로젝트 개요

본 분석은 xAPI-Edu-Data 데이터셋을 활용하여 학생의 학습 성과를 예측하는 머신러닝 모델을 구축하는 것을 목표로 합니다.

- 분석 목적: 학생의 행동 패턴과 배경 정보를 기반으로 성적 등급(Low/Medium/High) 예측
- 사용 모델: XGBoost Classifier
- 주요 기법: 탐색적 데이터 분석(EDA), Label Encoding, 분류 모델링

2. 데이터 개요

2.1 데이터 구조

- 총 샘플 수: 480개
- 총 변수 수: 17개 (피처 16개 + 타겟 1개)
- 결측치: 없음

2.2 변수 설명

범주형 변수 (12개)

- gender : 학생의 성별 (M: 남성, F: 여성)
- NationalITY : 학생의 국적
- PlaceofBirth : 학생이 태어난 국가
- StageID : 학생이 다니는 학교 단계 (초등/중등/고등)
- GradeID : 학생이 속한 성적 등급
- SectionID : 학생이 속한 반
- Topic : 수강한 과목
- Semester : 수강한 학기 (1학기/2학기)
- Relation : 주 보호자와 학생의 관계
- ParentAnsweringSurvey : 부모의 설문 참여 여부
- ParentschoolSatisfaction : 부모의 학교 만족도
- StudentAbsenceDays : 학생의 결석 횟수 (7회 이상/미만)


수치형 변수 (4개)

- raisedhands : 수업 중 손을 든 횟수 (평균: 46.8회)
- VisITedResources : 과목 공지 확인 횟수 (평균: 54.8회)
- AnnouncementsView : 공지사항 조회 횟수 (평균: 37.9회)
- Discussion : 토론 그룹 참여 횟수 (평균: 43.3회)

타겟 변수

- Class : 학생의 성적 등급
 - H (High): 142명 (29.6%)
 - M (Medium): 211명 (44.0%)
 - L (Low): 127명 (26.5%)


2.3 타겟 변수 분포



클래스 분포가 비교적 균형적이며, Medium 등급이 가장 많고 Low 등급이 가장 적습니다.

3. 탐색적 데이터 분석 (EDA)

3.1 수치형 변수와 성적의 관계



주요 인사이트:

- **raisedhands (손들기 횟수):** High 등급 학생들이 평균적으로 더 많은 질문을 하는 경향이 있습니다.
- **VisiTedResources (자료 확인):** High 등급 학생들이 학습 자료를 더 자주 확인합니다.
- **Discussion (토론 참여):** High 등급 학생들의 토론 참여도가 현저히 높습니다.
- **AnnouncementsView (공지 확인):** High 등급 학생들이 공지사항을 더 적극적으로 확인합니다.

결론: 학습에 대한 적극성과 참여도가 높을수록 성적이 높은 경향이 뚜렷합니다.

4. 데이터 전처리

4.1 변수 인코딩

모든 범주형 변수에 대해 Label Encoding을 적용했습니다.

- 총 12개의 범주형 변수 인코딩
- 타겟 변수: H=0, L=1, M=2로 매핑

4.2 데이터 분할

- 학습 데이터: 384개 (80%)
- 테스트 데이터: 96개 (20%)
- 분할 방식: Stratified Split (클래스 비율 유지)

5. 모델링 및 평가

5.1 모델 선택


XGBoost Classifier 사용

- `n_estimators` : 100
- `max_depth` : 6
- `learning_rate` : 0.1
- `eval_metric` : mlogloss

5.2 모델 성능

지표	값
정확도 (Accuracy)	77.08%
정밀도 (Macro Precision)	77.56%
재현율 (Macro Recall)	77.90%
F1 Score (Macro)	77.62%
ROC-AUC Score (OvR)	0.8930

5.3 ROC Curve (One-vs-Rest)




분석:

- 모든 클래스에서 AUC가 0.85 이상으로 높은 변별력을 보입니다.
- 특히 **Low (L)** 등급의 AUC가 0.97로 가장 높아, 학습 부진 위험이 있는 학생을 식별하는 성능이 매우 탁월합니다.

5.4 클래스별 성능

Class	Precision	Recall	F1-Score	Support
H (High)	0.73	0.66	0.69	29
L (Low)	0.85	0.92	0.88	25
M (Medium)	0.74	0.76	0.75	42
전체	0.77	0.77	0.77	96


5.5 Confusion Matrix



주요 오분류 패턴:

- High 등급 학생 중 일부가 Medium으로 분류되는 경향이 있음 (73% Precision)
- Low 등급의 경우 92%의 매우 높은 재현율(Recall)을 기록하여 실제 성적이 낮은 학생을 거의 놓치지 않고 찾아냄

6. Feature Importance 분석



6.1 주요 변수 (Top 10)

순위	변수명	중요도	설명
1	StudentAbsenceDays	0.398	결석 횟수 (가장 중요!)
2	Relation	0.091	보호자 관계
3	VisITedResources	0.070	학습 자료 확인 횟수
4	raisedhands	0.061	수업 중 질문 횟수
5	gender	0.049	성별
6	ParentschoolSatisfaction	0.043	부모 만족도
7	AnnouncementsView	0.039	공지 확인 횟수
8	ParentAnsweringSurvey	0.034	부모 설문 참여
9	Discussion	0.034	토론 참여도
10	NationalITy	0.031	국적

6.2 핵심 인사이트

[!IMPORTANT] > 결석 횟수(**StudentAbsenceDays**)가 성적을 결정하는 가장 중요한 요인입니다. 전체 중요도의 약 40%를 차지하며, 다른 모든 변수를 압도합니다.

- **출석의 중요성:** 결석이 적을수록 성적이 높아질 확률이 크게 증가합니다.
- **학습 참여도:** 자료 확인, 질문, 토론 참여 등 적극적인 학습 태도가 성적에 긍정적인 영향을 미칩니다.
- **가정 환경:** 부모의 학교 만족도와 설문 참여도도 학생 성과와 관련이 있습니다.

7. 결론 및 제언

7.1 주요 발견사항

1. **출석이 성공의 핵심:** 결석 횟수가 성적 예측에서 가장 중요하게 나타났습니다.
2. **적극적 참여의 효과:** 손들기, 토론 참여, 자료 확인 등 능동적인 학습 태도가 높은 성적과 강한 상관관계를 보입니다.
3. **부모의 역할:** 부모의 학교 만족도와 참여도 또한 학생 성적에 긍정적인 영향을 미칩니다.

7.2 모델 성능 평가

- XGBoost 모델은 **77.08%의 정확도**와 **0.893의 ROC-AUC**로 우수한 성능을 보였습니다.
- 특히 Low 등급 학생을 식별하는 데 매우 효과적입니다 (Recall 92%).
- 실무에서 조기 개입이 필요한 저성적 학생을 찾아내는 데 활용 가능합니다.

7.3 실무 적용 제언

[!TIP] > 조기 경보 시스템 구축

- 결석이 잦은 학생에게 즉각적인 상담 제공
- 학습 참여도가 낮은 학생에게 멘토링 프로그램 연결
- 부모 참여를 독려하는 프로그램 운영

8. 기술 스택

- 언어: Python 3
- 주요 라이브러리:
 - 데이터 처리: `pandas` , `numpy`
 - 시각화: `matplotlib` , `seaborn`
 - 머신러닝: `scikit-learn` , `xgboost`
- 평가 지표: Accuracy, Precision, Recall, F1-Score, ROC-AUC, Confusion Matrix